06. Metadata Analyzer , v0.2.0

> **Analizador de metadatos orientado a auditoría, investigación forense, validación documental y clasificación preliminar de riesgo.**

Tabla de Contenidos

- Descripción General
- Características Principales
- Casos de Uso
- Arquitectura del Proyecto
- Tecnologías Utilizadas
- Instalación y Configuración
- Uso Básico
- Formatos de Salida
- Ejemplo de Resultados
- Clasificación de Riesgo
- Roadmap
- Contribuciones
- Licencia

Descripción General

Metadata Analyzer es una herramienta de línea de comandos desarrollada en Python que permite extraer, analizar y clasificar metadatos de diversos tipos de archivos. Está diseñada para profesionales en:

- **Auditoría y cumplimiento**
- **Investigación forense digital**
- **Validación documental**
- **Clasificación preliminar de riesgo**

La herramienta no solo extrae metadatos, sino que también aplica heurísticas para detectar archivos sospechosos y genera reportes en múltiples formatos para facilitar el análisis posterior.

Características Principales

Extracción de Metadatos por Tipo de Archivo

Tipo de Archivo	Formatos Soportados	Metadatos Extraídos
Imágenes	JPG, PNG, GIF, BMP, TIFF	EXIF, GPS (decimal), cámara, fecha, dimensiones
PDF	PDF	Autor, título, creador, fechas, versión PDF
Word	DOC, DOCX	Autor, título, asunto, fechas, última impresión
Excel	XLS, XLSX	Autor, título, compañía, fechas, última modificación
PowerPoint	PPT, PPTX	Autor, título, presentación, fechas
Genéricos	Cualquier archivo	Metadatos básicos del sistema de archivos

Identificación de Metadatos Comunes

- Fecha de creación
- Fecha de modificación
- Fecha de último acceso
- Autor
- Título
- Asunto
- Compañía/Organización
- Último impresor (PDF)

Cálculo de Hashes

- **MD5**: Para verificación rápida de integridad
- **SHA-256**: Para identificación forense robusta

Detección de Duplicados

- Por **hash** (MD5/SHA-256)
- Por **nombre + tamaño** (para detección preliminar)

Extracción GPS

- Lectura de coordenadas EXIF en imágenes
- Conversión a formato decimal (latitud/longitud)
- Preparado para integración con mapas

Heurísticas de Detección de Archivos Sospechosos

- Metadatos inconsistentes (ej: fecha de creación posterior a modificación)
- Autores genéricos o vacíos
- Coordenadas GPS en ubicaciones sensibles
- Archivos con múltiples versiones sospechosas

Clasificación Automática

- **Por tipo**: Imagen, documento, hoja de cálculo, presentación, etc.
- **Por sensibilidad**: Bajo, medio, alto (basado en autor, ubicación, etc.)
- **Por riesgo**: Verde, amarillo, rojo (basado en heurísticas)

Reportes en Múltiples Formatos

- **JSON**: Para procesamiento programático
- **CSV**: Para análisis en Excel/hojas de cálculo
- **TXT**: Para revisión rápida
- **HTML**: Para visualización en navegador (formato legible)

Casos de Uso

Sector	Aplicación	Beneficio
Auditoría	Validar autenticidad de documentos	Detectar documentos falsificados
Legal	Análisis de evidencia digital	Cadena de custodia robusta
Seguridad	Clasificación de documentos sensibles	Prevenir fugas de información
Forense	Investigación de incidentes	Identificar origen de archivos
Gestión Documental	Organización de archivos	Eliminar duplicados eficientemente
Cumplimiento	Auditoría interna	Verificar políticas de metadata

---

Tecnologías Utilizadas

PYTHON | PILLOW | PYPDF2 | PYTHON-DOCX | OPENPYXL | PYTHON-PPTX

Librería	Versión	Uso Principal
Python	≥3.8	Lenguaje principal
Pillow	≥10.0	Extracción EXIF de imágenes
PyPDF2	≥3.0	Metadatos de PDF
python-docx	≥0.8	Metadatos de Word
openpyxl	≥3.1	Metadatos de Excel
python-pptx	≥0.6	Metadatos de PowerPoint

Librería	Versión	Uso Principal
argparse	estándar	Interfaz CLI
hashlib	estándar	Cálculo de hashes
json	estándar	Reportes JSON
csv	estándar	Reportes CSV

Instalación y Configuración

Prerrequisitos

- Python 3.8 o superior
- pip (gestor de paquetes)
- Git (opcional)

Pasos de Instalación

```
# 1. Clonar el repositorio (opcional)
git clone https://github.com/KPforusesmain/metadata-analyzer.git
cd metadata-analyzer

# 2. Crear entorno virtual
python -m venv .venv

# 3. Activar entorno virtual
# En Windows:
.venv\Scripts\activate
# En Linux/Mac:
source .venv/bin/activate

# 4. Instalar dependencias
pip install -r requirements.txt

# 5. Verificar instalación
python -m metadata_analyzer.cli.main --version
```

Archivo `requirements.txt`

```
Pillow>=10.0.0
PyPDF2>=3.0.0
python-docx>=0.8.11
openpyxl>=3.1.0
python-pptx>=0.6.21
```

Uso Básico

Analizar un archivo específico

```
# Analizar una imagen
python -m metadata_analyzer.cli.main analizar imagen.jpg

# Analizar un PDF
python -m metadata_analyzer.cli.main analizar documento.pdf

# Analizar múltiples archivos
python -m metadata_analyzer.cli.main analizar archivo1.jpg archivo2.pdf
archivo3.docx
```

Analizar un directorio completo

```
# Analizar todos los archivos en un directorio
python -m metadata_analyzer.cli.main analizar-directorio ./documentos/

# Con filtro por extensión
python -m metadata_analyzer.cli.main analizar-directorio ./fotos/ --extension
jpg,png

# Con búsqueda recursiva
python -m metadata_analyzer.cli.main analizar-directorio ./ --recursivo
```

Detección de duplicados

```
# Buscar duplicados por hash
python -m metadata_analyzer.cli.main buscar-duplicados ./documentos/

# Buscar duplicados por nombre + tamaño
python -m metadata_analyzer.cli.main buscar-duplicados ./ --metodo nombre-
tamano

# Generar reporte de duplicados
python -m metadata_analyzer.cli.main buscar-duplicados ./ --reporte
duplicados.csv
```

Exportar reportes

```
# Reporte en JSON
python -m metadata_analyzer.cli.main analizar-directorio ./ --formato json --
output reporte.json

# Reporte en CSV
python -m metadata_analyzer.cli.main analizar-directorio ./ --formato csv --
output metadatos.csv

# Reporte en HTML (legible)
python -m metadata_analyzer.cli.main analizar-directorio ./ --formato html --
output reporte.html

# Todos los formatos
python -m metadata_analyzer.cli.main analizar-directorio ./ --formato todos --
output ./reportes/
```

Parámetros adicionales

```
# Modo verboso (más información)
python -m metadata_analyzer.cli.main analizar archivo.jpg --verbose

# Incluir hash SHA-256
python -m metadata_analyzer.cli.main analizar archivo.pdf --sha256

# Excluir archivos por patrón
python -m metadata_analyzer.cli.main analizar-directorio ./ --excluir
"*.tmp,*.bak"
```

Formatos de Salida

JSON (Para procesamiento programático)

```
{
  "archivo": "imagen.jpg",
  "ruta": "/home/user/fotos/imagen.jpg",
  "tamaño_bytes": 2457600,
  "hashes": {
    "md5": "a1b2c3d4e5f6...",
    "sha256":
"e3b0c44298fc1c149afbf4c8996fb92427ae41e4649b934ca495991b7852b855"
  },
```

```
  "metadatos": {
    "fecha_creacion": "2024-01-15 14:30:22",
    "fecha_modificacion": "2024-01-16 09:45:10",
    "fecha_acceso": "2024-01-17 11:20:05",
    "autor": "Usuario",
    "exif": {
      "camera": "Canon EOS 5D",
      "fecha_toma": "2024-01-14 10:15:30",
      "gps": {
        "latitud": 9.9281,
        "longitud": -84.0907
      }
    }
  },
  "clasificacion": {
    "tipo": "imagen",
    "sensibilidad": "media",
    "riesgo": "amarillo"
  }
}
```

CSV (Para análisis en Excel)

```
archivo,ruta,tipo,fecha_creacion,autor,hash_md5,riesgo
imagen1.jpg,/fotos/imagen1.jpg,imagen,2024-01-15,Usuario,a1b2c3d4,verde
documento.pdf,/docs/documento.pdf,pdf,2023-12-10,Admin,e5f6g7h8,amarillo
```

HTML (Visualización en navegador)

El reporte HTML incluye:

- Resumen ejecutivo con estadísticas
- Tablas interactivas de metadatos
- Clasificación por color (verde/amarillo/rojo)
- Sección de duplicados encontrados
- Gráficos de distribución por tipo
- Expandible/colapsable para detalles

Ejemplo de Resultados

Análisis de Imagen con GPS

```
$ python -m metadata_analyzer.cli.main analizar vacaciones.jpg --verbose
```

```
METADATA ANALYZER v0.2.0
==================================================
Archivo: vacaciones.jpg
Ruta: /home/user/fotos/vacaciones.jpg
Tamaño: 3.2 MB

METADATOS BÁSICOS
--------------------------------------------------
• Fecha creación: 2024-01-15 10:30:22
• Fecha modificación: 2024-01-15 10:30:25
• Fecha acceso: 2024-03-10 15:45:10
• Propietario: usuario

METADATOS EXIF
--------------------------------------------------
• Cámara: Canon EOS 5D Mark IV
• Modelo: Canon EOS 5D Mark IV
• Fecha toma: 2024-01-14 15:30:00
• ISO: 400
• Apertura: f/8.0
• Velocidad: 1/250s
• Flash: No

COORDENADAS GPS
--------------------------------------------------
• Latitud: 9.9281° N
• Longitud: -84.0907° W
• Altitud: 1172 msnm
• Ubicación: San José, Costa Rica
https://maps.google.com/?q=9.9281,-84.0907

HASHES
--------------------------------------------------
• MD5: a1b2c3d4e5f67890abcdef1234567890
• SHA-256: e3b0c44298fc1c149afbf4c8996fb924...

CLASIFICACIÓN
--------------------------------------------------
```

```
• Tipo: Imagen
• Sensibilidad: Media (contiene GPS)
• Riesgo: Amarillo

Análisis completado en 0.3 segundos
```

Detección de Duplicados

```
$ python -m metadata_analyzer.cli.main buscar-duplicados ./documentos/ --
metodo hash
```

```
BÚSQUEDA DE DUPLICADOS
==================================================
Directorio analizado: ./documentos/
Archivos totales: 150
Método: Hash (MD5)

GRUPOS DE DUPLICADOS
--------------------------------------------------
Grupo 1 (hash: a1b2c3d4...)
  • ./documentos/reporte_final.pdf
  • ./documentos/backup/reporte_final.pdf
  • ./documentos/copias/reporte_final_copia.pdf

Grupo 2 (hash: e5f6g7h8...)
  • ./documentos/imagenes/foto_playa.jpg
  • ./documentos/fotos_viejas/playa_2023.jpg

ESTADÍSTICAS
--------------------------------------------------
• Archivos duplicados: 45 (30% del total)
• Espacio desperdiciado: 127 MB
• Grupos de duplicados: 12

Búsqueda completada en 1.2 segundos
```

Clasificación de Riesgo

Criterios de Clasificación

Nivel	Color	Criterios	Ejemplo
Bajo	Verde	Metadatos estándar, autor conocido, sin GPS	Documento interno corporativo
Medio	Amarillo	GPS presente, autor genérico, fechas inconsistentes	Foto con ubicación personal
Alto	Rojo	Múltiples alertas, autor removido, metadatos inconsistentes	Documento anónimo con fechas alteradas

Heurísticas Implementadas

```python
# Ejemplo de lógica de clasificación
def clasificar_riesgo(metadata):
    puntuacion = 0
    alertas = []

    # 1. Verificar autor
    if not metadata.get('autor') or metadata['autor'] in ['', 'Desconocido']:
        puntuacion += 2
        alertas.append("Autor no identificado")

    # 2. Verificar fechas
    if metadata.get('fecha_creacion') > metadata.get('fecha_modificacion'):
        puntuacion += 3
        alertas.append("Fecha de modificación anterior a creación")

    # 3. Verificar GPS en ubicación sensible
    if metadata.get('gps'):
        lat, lon = metadata['gps']
        if ubicacion_sensible(lat, lon):
            puntuacion += 3
            alertas.append("GPS en ubicación sensible")

    # 4. Clasificación final
    if puntuacion >= 5:
        return "ALTO", alertas
    elif puntuacion >= 2:
        return "MEDIO", alertas
```

```
    else:
        return "BAJO", alertas
```

Versión 0.2.0 (Actual)

- ✅ GPS EXIF en formato decimal
- ✅ Reporte HTML legible
- ✅ Duplicados por nombre + tamaño
- ✅ Soporte inicial para PowerPoint

Versión 0.3.0 (Próxima)

- [ ] Configuración por YAML
- [ ] Cadena de custodia (log de auditoría)
- [ ] Exportación a PDF
- [ ] Base de datos SQLite para histórico
- [ ] Firma digital de reportes

Versión 0.4.0 (Futuro)

- [ ] Dashboard web interactivo
- [ ] Soporte para archivos ZIP (análisis recursivo)
- [ ] Reglas avanzadas de análisis (YARA)
- [ ] Mejoras en clasificación por riesgo (ML)
- [ ] API REST para integración

Versión 1.0.0 (Visión)

- [ ] Interfaz gráfica (Tkinter/Streamlit)
- [ ] Plugins personalizables
- [ ] Análisis en tiempo real
- [ ] Integración con SIEM
- [ ] Modo forense con preservación de evidencia

Guía de Estilo

- Seguir PEP 8
- Incluir tests para nuevas funcionalidades
- Actualizar documentación
- Usar type hints cuando sea posible
- Mantener compatibilidad hacia atrás

Licencia

Este proyecto está bajo la **Licencia MIT**.
Ver el archivo LICENSE para más detalles.

MIT License

Copyright (c) 2024 Metadata Analyzer

Permission is hereby granted, free of charge, to any person obtaining a copy of this software and associated documentation files...

GITHUB LINKEDIN EMAIL