Modelo de Pronóstico de Ventas

> **Proyecto de analítica predictiva enfocado en la estimación de ventas futuras mediante técnicas de series temporales y modelos baseline. Transforma datos históricos en proyecciones accionables para la toma de decisiones comerciales.**

Tabla de Contenidos

- Descripción General
- El Problema
- Solución Propuesta
- Objetivos del Proyecto
- Tecnologías Utilizadas
- Metodología
- Modelos Implementados
- Métricas de Evaluación
- Estructura del Proyecto
- Instalación y Configuración
- Ejecución del Proyecto
- Resultados Esperados
- Recomendaciones de Negocio
- Casos de Uso
- Mejoras Futuras
- Valor para Portafolio
- Autor y Licencia

Descripción General

Este proyecto implementa un **sistema de pronóstico de ventas** utilizando técnicas de series temporales y modelos baseline. El objetivo es proporcionar una herramienta que permita:

- **Transformar datos históricos** en proyecciones confiables
- **Identificar patrones** estacionales y tendencias
- **Evaluar múltiples modelos** de pronóstico
- **Generar insights** accionables para el negocio

El proyecto está diseñado para ser **reproducible, modular y escalable**, sirviendo tanto para uso profesional como para portafolio personal.

El Problema

Muchas empresas registran ventas históricas, pero **no convierten esa información en pronósticos accionables**. Esto genera:

Desafío	Impacto en el Negocio
Planificación de inventario	Exceso de stock o desabastecimiento
Estimación de ingresos	Incertidumbre financiera
Patrones estacionales	Oportunidades perdidas
Picos de demanda	Falta de preparación operativa
Caídas inesperadas	Pérdidas no anticipadas

Solución Propuesta

Se desarrolló un **flujo reproducible en Python** que automatiza todo el proceso de pronóstico:

```
A [Datos Históricos] --> B[Limpieza y Preparación]
B --> C[Entrenamiento de Modelos]
C --> D[Evaluación con Métricas]
D --> E[Visualización]
E --> F[Recomendaciones de Negocio]
```

Características Clave:

- ✅ **Flexibilidad**: Trabaja con datos reales o simulados
- ✅ **Múltiples Modelos**: Compara 5+ enfoques de pronóstico
- ✅ **Métricas Objetivas**: MAE, RMSE, MAPE para evaluación
- ✅ **Visualización Clara**: Gráficos interpretables
- ✅ **Business Insights**: Recomendaciones accionables

Objetivos del Proyecto

Objetivo	Descripción	Estado
Baseline Sólido	Construir modelos baseline de pronóstico	✅ Completado
Comparación de Modelos	Evaluar múltiples enfoques	✅ Completado
Métricas de Precisión	MAE, RMSE, MAPE	✅ Completado
Recomendaciones	Traducir resultados a insights de negocio	✅ Completado
Reproducibilidad	Proyecto modular y documentado	✅ Completado
Modelos Avanzados	LSTM, Prophet	🚧 En desarrollo

Tecnologías Utilizadas

PYTHON | PANDAS | NUMPY | MATPLOTLIB | SCIKIT-LEARN | STATSMODELS | JUPYTER | GITHUB

Tecnología	Versión	Uso Principal
Python	≥3.8	Lenguaje principal
Pandas	≥2.0	Manipulación de datos
NumPy	≥1.24	Operaciones numéricas
Matplotlib	≥3.7	Visualización

Tecnología	Versión	Uso Principal
Statsmodels	≥0.14	Modelos estadísticos (ETS, ARIMA)
Scikit-learn	≥1.3	Métricas y preprocessing
Jupyter	≥6.0	Notebooks de exploración

Metodología

Fase 1: Generación o Carga de Datos

El proyecto puede trabajar con dos fuentes:

```
# Opción 1: Datos sintéticos generados automáticamente
ventas = generar_datos_sinteticos(periodos=24, tendencia=0.05,
estacionalidad=0.2)

# Opción 2: Datos reales desde CSV
ventas = pd.read_csv('data/raw/ventas_historicas.csv')
```

Fase 2: Preparación de Datos

Tarea	Descripción
Conversión de fechas	`pd.to_datetime()` con formato adecuado
Ordenamiento	Asegurar secuencia cronológica
Valores faltantes	Interpolación o relleno hacia atrás/adelante
Agregación	Resampling diario/semanal/mensual
Variables derivadas	Día de semana, mes, trimestre, etc.

Fase 3: Modelado

```
    A [Datos Preparados] --> B[Train/Test Split]
    B --> C[Entrenamiento Modelos]
    C --> D[Naive Forecast]
    C --> E[Promedio Móvil]
```

```
    C --> F[ETS]
    C --> G[ARIMA]
    C --> H[Regresión Temporal]
    D --> I[Evaluación]
```

Fase 4: Evaluación

Se utilizan métricas estándar para comparar modelos:

- **MAE** (Error Absoluto Medio): `mean(abs(real - predicción))`
- **RMSE** (Raíz del Error Cuadrático Medio): `sqrt(mean((real - predicción)²))`
- **MAPE** (Error Porcentual Absoluto Medio): `mean(abs((real - predicción)/real)) * 100`

Fase 5: Visualización

Se generan gráficos clave:

```
# Ejemplo de visualizaciones generadas
- Serie temporal histórica
- Descomposición (tendencia + estacionalidad + residuo)
- Comparación real vs predicción
- Comparativa de modelos
- Pronóstico extendido
```

Fase 6: Recomendaciones de Negocio

El sistema genera insights automáticos basados en:

- Patrones estacionales detectados
- Tendencias identificadas
- Precisión de cada modelo
- Riesgos de sobre/subestimación

Modelos Implementados

Modelo	Descripción	Ventajas	Limitaciones
Naive Forecast	El valor del período anterior es el pronóstico	Simple, baseline	No captura patrones

Modelo	Descripción	Ventajas	Limitaciones
Promedio Móvil	Promedio de últimos N períodos	Suaviza ruido	Ignora tendencia
ETS	Suavizado exponencial con tendencia/estacionalidad	Captura patrones	Parámetros fijos
ARIMA	Modelo autorregresivo integrado de media móvil	Flexible, poderoso	Complejo de parametrizar
Regresión Temporal	Variables como tiempo, mes, día	Interpretable	Asume linealidad

Ejemplo de Resultados (Datos Sintéticos)

Modelo	MAE	RMSE	MAPE
Naive	245.3	312.8	8.2%
Promedio Móvil (3)	187.6	241.5	6.1%
ETS	**142.1**	**189.3**	**4.8%**
ARIMA	158.4	203.7	5.3%
Regresión	201.2	267.9	6.9%

Métricas de Evaluación

MAE (Error Absoluto Medio)

```
from sklearn.metrics import mean_absolute_error
mae = mean_absolute_error(y_test, y_pred)
# Interpretación: En promedio, el error es de ±X unidades
```

RMSE (Raíz del Error Cuadrático Medio)

```
from sklearn.metrics import mean_squared_error
rmse = np.sqrt(mean_squared_error(y_test, y_pred))
# Interpretación: Penaliza más los errores grandes
```

MAPE (Error Porcentual Absoluto Medio)

```
def mape(y_true, y_pred):
    return np.mean(np.abs((y_true - y_pred) / y_true)) * 100
# Interpretación: Error porcentual promedio
```

Instalación y Configuración

Prerrequisitos

- Python 3.8 o superior
- pip (gestor de paquetes)
- Git

Pasos de Instalación

```
# 1. Clonar el repositorio
git clone https://github.com/KPforusesmain/modelo-pronostico-ventas.git
cd modelo-pronostico-ventas

# 2. Crear entorno virtual (opcional pero recomendado)
python -m venv .venv

# 3. Activar entorno virtual
# En Windows:
.venv\Scripts\activate
# En Linux/Mac:
source .venv/bin/activate

# 4. Instalar dependencias
pip install -r requirements.txt

# 5. Verificar instalación
python -c "import pandas; print(f'Pandas version: {pandas.__version__}')"
```

Archivo `requirements.txt`

```
pandas>=2.0.0
numpy>=1.24.0
matplotlib>=3.7.0
statsmodels>=0.14.0
```

```
scikit-learn>=1.3.0
jupyter>=6.0.0
seaborn>=0.12.0  # Opcional, para visualización mejorada
```

Ejecución del Proyecto

Opción 1: Usando datos sintéticos

```
# Generar datos y ejecutar todo el pipeline
python -m src.main --synthetic --periods 36 --forecast_horizon 6
```

Opción 2: Usando datos propios (CSV)

```
# Especificar archivo de datos
python -m src.main --data_path data/raw/mis_ventas.csv --forecast_horizon 6
```

Opción 3: Exploración con Jupyter

```
# Iniciar Jupyter Lab
jupyter lab

# Navegar a notebooks/ y ejecutar celdas
```

Parámetros de Configuración

Parámetro	Descripción	Default
`--synthetic`	Usar datos sintéticos	`False`
`--periods`	Número de períodos (sintético)	36
`--data_path`	Ruta al archivo CSV	`None`
`--forecast_horizon`	Períodos a pronosticar	6
`--test_size`	% para test	0.2
`--models`	Modelos a ejecutar	"todos"

Resultados Esperados

Ejemplo de Visualización

```
Serie Temporal de Ventas
   ↑
8000|    ∩      ∩∩    ∩    ∩
6000|   ╱ ╲    ╱ ∪ ╲  ╱ ╲  ╱ ╲
4000|  ╱   ╲  ╱    ╲╱   ╲╱   ╲
2000|_╱     ╲╱      ∪     ∪     ╲__
   └──────────────────────────────────→
     Ene Mar May Jul Sep Nov Ene Mar
```

Reporte de Evaluación

```
==================================================
EVALUACIÓN DE MODELOS DE PRONÓSTICO
==================================================
Dataset: Ventas mensuales (36 meses)
Train/Test: 30 meses / 6 meses

RESULTADOS POR MODELO
--------------------------------------------------
Naive Forecast:
  • MAE:  245.3
  • RMSE: 312.8
  • MAPE: 8.2%

Promedio Móvil (ventana=3):
  • MAE:  187.6
  • RMSE: 241.5
  • MAPE: 6.1%

ETS (Exponential Smoothing):
  • MAE:  142.1 ✓ MEJOR
  • RMSE: 189.3 ✓ MEJOR
  • MAPE: 4.8% ✓ MEJOR

ARIMA(1,1,1):
  • MAE:  158.4
  • RMSE: 203.7
  • MAPE: 5.3%

Regresión Temporal:
```

```
  • MAE:  201.2
  • RMSE: 267.9
  • MAPE: 6.9%

CONCLUSIÓN
--------------------------------------------------
El modelo ETS presenta el mejor desempeño con un
error promedio de 4.8% (MAPE). Se recomienda su uso
para pronósticos operativos.

TIEMPO TOTAL DE EJECUCIÓN: 3.2 segundos
==================================================
```

Pronóstico Extendido

```
PRONÓSTICO PARA PRÓXIMOS 6 MESES
--------------------------------------------------
Mes 1:  Estimación: 5,234 ± 189
Mes 2:  Estimación: 5,876 ± 203
Mes 3:  Estimación: 6,451 ± 231
Mes 4:  Estimación: 5,987 ± 198
Mes 5:  Estimación: 5,432 ± 176
Mes 6:  Estimación: 6,123 ± 215
--------------------------------------------------
```

Recomendaciones de Negocio

El sistema genera insights accionables basados en los resultados:

Insights Detectados Automáticamente

```
ANÁLISIS DE PATRONES
==================================================
ESTACIONALIDAD
--------------------------------------------------
• Pico de ventas en Diciembre (+45% vs promedio)
• Valle en Febrero (-30% vs promedio)
• Tendencia creciente de +2.3% mensual

RECOMENDACIONES DE INVENTARIO
--------------------------------------------------
- Aumentar stock 40% en Noviembre para pico Diciembre
```

```
- Reducir inventario 25% en Enero para evitar sobrestock
- Preparar promociones para Febrero (valle estacional)

PLANIFICACIÓN FINANCIERA
--------------------------------------------------
• Ingreso proyectado próximo trimestre: $187,500 ± $8,200
• Mejor momento para inversiones: Marzo-Abril
• Riesgo de sobreestimación: 12% en meses pico

ALERTAS
--------------------------------------------------
- Posible desabastecimiento en Diciembre si no se planifica
- Caída estacional en Febrero requiere estrategia promocional
- Tendencia positiva consistente en últimos 12 meses

ACCIONES RECOMENDADAS
--------------------------------------------------
1. Implementar forecast rolling mensual
2. Ajustar compras según estacionalidad detectada
3. Monitorear MAPE mensualmente
4. Reentrenar modelo cada 3 meses
==================================================
```

Casos de Uso

Este proyecto puede aplicarse en diversos contextos:

Caso	Descripción	Beneficio
Retail	Pronóstico de ventas por tienda/categoría	Optimización de inventario
Manufactura	Planificación de producción	Reducción de costos
Logística	Demanda de envíos	Mejor asignación de recursos
Finanzas	Proyección de ingresos	Presupuestos precisos
Marketing	Respuesta a campañas	ROI optimizado
PYMEs	Planificación general	Toma de decisiones informada

Mejoras Futuras

Corto Plazo

- [ ] Interfaz web con Streamlit para uso interactivo
- [ ] Más modelos (Prophet, XGBoost, LSTM)
- [ ] Intervalos de confianza en pronósticos
- [ ] Exportación a Excel de resultados

Mediano Plazo

- [ ] Detección automática de outliers
- [ ] Múltiples granularidades (diario, semanal, mensual)
- [ ] API REST para integración con otros sistemas
- [ ] Dashboard interactivo con métricas en tiempo real

Largo Plazo

- [ ] Machine Learning automático (AutoML)
- [ ] Integración con fuentes de datos externas (clima, economía)
- [ ] Alertas automáticas por desviaciones
- [ ] Versión SaaS multi-tenant

Valor para Portafolio

Este proyecto demuestra capacidades en:

Área	Habilidades Demostradas
Análisis de Datos	Pandas, limpieza, transformación
Series Temporales	ETS, ARIMA, descomposición
Machine Learning	Scikit-learn, métricas, evaluación
Visualización	Matplotlib, gráficos interpretables
Python	Programación modular, POO
Arquitectura	Estructura limpia y escalable
Documentación	README completo, comentarios

Área	Habilidades Demostradas
Business Acumen	Insights accionables, recomendaciones

Habilidades Específicas Destacadas

✅ **Técnicas:**

- Manipulación avanzada de datos con Pandas
- Modelado de series temporales
- Evaluación con métricas estadísticas
- Visualización de resultados

✅ **De Negocio:**

- Traducción de resultados técnicos a insights
- Recomendaciones basadas en datos
- Comprensión del contexto comercial
- Comunicación efectiva de hallazgos

✅ **De Proyecto:**

- Estructura modular y mantenible
- Código reproducible
- Documentación exhaustiva
- Preparado para escalar

Autor y Licencia

Autor

Proyecto personal desarrollado como parte de un portafolio orientado a **analítica predictiva, machine learning y ciencia de datos aplicada a negocios**.

GITHUB LINKEDIN

Referencias y Recursos

- Forecasting: Principles and Practice - Libro de referencia
- Statsmodels Documentation
- Scikit-learn User Guide
- Python Data Science Handbook